

DOSSIER DE PROTOTYPAGE

RealEstateAI

Estimateur de prix immobilier — Île-de-France
Basé sur les données DVF open data

Prototype v1.0 · Mars 2026
<https://github.com/khadija10/RealStateAI>

1. CONTEXTE

Présentation du contexte

Le marché immobilier francilien est complexe, fragmenté et opaque pour les particuliers. Les transactions immobilières en Île-de-France représentent plusieurs centaines de milliers d'opérations annuelles, mais il n'existe pas d'outil simple, gratuit et basé sur des données réelles permettant à un vendeur ou acheteur d'obtenir rapidement une estimation de prix fiable.

L'État français publie en open data les **Demandes de Valeurs Foncières (DVF)**, un registre exhaustif de toutes les ventes immobilières notariées. Ce jeu de données constitue une base de travail exceptionnelle, encore peu exploitée sous forme d'application accessible au grand public.

Objectifs du POC

Valider la faisabilité technique d'un estimateur de prix immobilier basé sur les données DVF réelles, accessible via une interface web, et retournant en quelques secondes une fourchette de prix de marché pour un bien donné en Île-de-France.

2. LE POC

Hypothèses du POC

- Les données DVF 2023–2024 contiennent suffisamment de transactions (≥ 10) par commune et type de bien pour produire une estimation statistiquement significative.
- Le prix d'un bien est linéairement proportionnel à sa surface (hypothèse simplificatrice acceptée pour ce stade).
- La commune est le niveau de granularité géographique suffisant pour le MVP.
- Les données DVF, une fois nettoyées, sont représentatives du marché réel sans biais majeur.
- L'infrastructure Docker garantit une reproductibilité totale du déploiement local.

Ce que le POC cherche à valider

- Faisabilité du pipeline complet : données brutes DVF → nettoyage → API → interface utilisateur.
- Pertinence d'une estimation statistique (médiane des prix au m²) comme approximation du prix de marché.
- Comparaison baseline statistique vs modèle Machine Learning simple (RandomForest).
- Ergonomie et utilisabilité d'une interface de saisie / résultat.

Éléments hors périmètre

- Géolocalisation fine (rue, quartier, étage, exposition).
- Historique et persistance des estimations (base de données).
- Données socio-économiques complémentaires (INSEE, revenus, etc.).
- Déploiement cloud / production.
- Authentification utilisateur.
- Couverture géographique hors Île-de-France.

Contraintes

- Données partielles : uniquement 2 années (2023–2024), uniquement maisons et appartements.
- Pas de filtre outliers automatique sur les prix extrêmes dans la version actuelle.
- Modèle ML limité par le faible nombre de features (commune, type, surface uniquement).

3. LES DONNÉES

Origine des données

Source : **Demandes de Valeurs Foncières (DVF)** — données ouvertes publiées par la Direction Générale des Finances Publiques (DGFIP) sur data.gouv.fr. Fichiers annuels au format TXT délimité par « | », couvrant l'intégralité des mutations immobilières notariées en France. Millésimes disponibles : 2022, 2023, 2024, 2025-S1. Dataset retenu pour le prototype : **DVF 2023–2024**.

Description rapide des données (après nettoyage)

Indicateur	Valeur
Transactions finales (2023–2024, IDF)	257 354
Types de biens	Appartement, Maison
Départements couverts	75, 77, 78, 91, 92, 93, 94, 95
Variables clés	commune, type_bien, surface_m2, prix_vente, prix_au_m2
Doublons (adresse + date + prix)	0
Lignes avec prix ≤ 0 après nettoyage	0
Présence d'outliers extrêmes	Oui (jusqu'à 2.5×10^8 €/m ²)

Boxplot des prix au m² — DVF 2023–2024 (IDF)

L'analyse de la distribution révèle la présence de valeurs aberrantes importantes (jusqu'à $2,5 \times 10^8$ €/m²), correspondant à des erreurs notariales ou des transactions atypiques. Paris (75) concentre les outliers les plus élevés. Le département 93 présente une variance plus importante que les autres. La médiane réelle se situe entre 3 000 et 15 000 €/m² selon la commune.

Note : Ces outliers ne sont pas encore filtrés automatiquement dans la version actuelle du pipeline. Un filtre IQR est prévu pour la version suivante.

Traitements effectués

1. Lecture des fichiers TXT (séparateur « | »), sélection des colonnes utiles uniquement.
2. Suppression des lignes sans Valeur foncière ou Surface réelle bâtie.
3. Conversion des types : virgule → point pour les numériques, parsing des dates.
4. Filtrage géographique : codes postaux à 5 chiffres, départements IDF uniquement (75, 77, 78, 91, 92, 93, 94, 95).
5. Filtrage métier : type_bien ∈ { Appartement → apartment, Maison → house }.
6. Calcul de prix_au_m2 = Valeur foncière / Surface (arrondi à 2 décimales).
7. Construction de la colonne adresse (concaténation normalisée).
8. Suppression des doublons stricts (adresse + date + prix).
9. Export CSV : DVF_clean_2023_2024.csv.

4. TECHNIQUE

Architecture de la solution

```
UTILISATEUR (Browser) — http://localhost:8501
  |
  ▼ HTTP
FRONTEND — React + Vite + TypeScript (port 8501)
  ├── Home.tsx           (page d'accueil)
  ├── Estimator.tsx      (formulaire d'estimation)
  └── EstimationResult.tsx (affichage résultat)
    |
    ▼ JSON REST
BACKEND — FastAPI (port 8000)
  ├── GET /api/health
  ├── GET /api/metadata/communes
  └── POST /api/predictions/estimate
      |
      ├── Modèle ML (RandomForest .pkl)
      └── DVF CSV (257 354 lignes)
```

Flux d'estimation

```
Requête POST /api/predictions/estimate
|
▼
Modèle ML disponible ?
  OUI → Prédiction RandomForest Pipeline
  NON → DVF chargé ?
        OUI → Recherche transactions similaires
              → médiane prix/m² × surface
        NON → Fallback mock (7 000 €/m²)
```

Algorithme de recherche DVF

```
1. Filtre strict : commune + type_bien + surface ± 20 %
2. Si vide → élargissement ± 35 %, puis ± 50 %
3. Si vide → fallback sur préfixe de commune
4. Calcul :
   prix_estimé = médiane(prix_au_m2) × surface
   borne_basse = Q1(prix_au_m2)      × surface
   borne_haute = Q3(prix_au_m2)      × surface
   confiance   = min(1.0 ; n_transactions / 50)
```

Outils et langages utilisés

Composant	Technologie	Version
Langage backend	Python	3.12
API REST	FastAPI	0.128
Validation données	Pydantic	2.12
Traitement données	Pandas	2.3
Machine Learning	scikit-learn	1.5.2
Sérialisation modèle	joblib	1.4
Frontend	React + Vite + TypeScript	—
CSS	Tailwind CSS	—
Conteneurisation	Docker + Docker Compose	—
Tests	pytest	9.0
Serveur ASGI	Uvicorn	0.40

Modèle Machine Learning

- Algorithme : RandomForestRegressor (200 arbres, random_state=42, n_jobs=-1).
- Features : commune (OneHotEncoded) + type_bien (OneHotEncoded) + surface_m2.
- Cible : prix_vente.
- Split : 80 % entraînement / 20 % validation.

Résultats d'évaluation (50 000 lignes DVF 2023–2024)

Modèle	MAE (€)	MAPE (%)
Baseline — médiane prix/m ² par commune + type	~190 882	~158.5 %
**RandomForest — commune + type + surface	~244 177	~182.0 %

La baseline statistique surpasse le RandomForest à ce stade. Les MAPE élevés s'expliquent par les outliers non filtrés et le manque de features discriminantes.

Justification des choix techniques

FastAPI a été retenu pour sa légèreté, sa documentation automatique (Swagger) et ses performances asynchrones. React + Vite offre un développement frontend réactif avec hot-reload, Tailwind CSS permettant un prototypage UI rapide sans configuration complexe. Le CSV remplace une base de données pour la simplicité de déploiement en phase prototype. scikit-learn fournit des pipelines reproductibles avec préprocessing intégré. Docker garantit une reproductibilité totale de l'environnement.

Alternative non retenue : **Streamlit** (frontend) — initialement envisagé pour sa simplicité Python, remplacé par React pour plus de contrôle UI et de maintenabilité long terme.

5. MANUEL D'UTILISATION

Lien Git : <https://github.com/khadija10/RealStateAI> — Branche **main** — Tag **v1.0**

Prototype : <http://localhost:8501> (après docker compose up --build)

API Swagger : <http://localhost:8000/docs>

Lancement rapide

```
git clone https://github.com/khadija10/RealStateAI.git
cd RealStateAI
python3 -m venv data_env && source data_env/bin/activate
pip install -r requirements.txt


# Générer le CSV nettoyé
cd "Backend/Data pipeline/Traitement"
python3 -c "from dvf_data_pipeline import pipeline_dvf; pipeline_dvf('../Data/', 2024)"
cd ~/RealStateAI
```

```
# Lancer l'application
sudo docker compose up --build -d
```

Fonctionnalité 1 — Page d'accueil

Présente les 3 piliers de l'outil (Données locales, Estimation rapide, Fourchette de prix) et oriente l'utilisateur vers le formulaire via un bouton d'appel à l'action.

Pilier	Description
Données Locales	Analyse basée sur les transactions réelles de la commune sélectionnée.
Estimation Rapide	Résultat obtenu en quelques secondes via l'API FastAPI.
Fourchette de Prix	Intervalle de confiance Q1–Q3 calculé sur les transactions similaires.



Fonctionnalité 2 — Formulaire d'estimation

L'utilisateur renseigne 5 champs pour décrire son bien :

Champ	Type de saisie	Exemple
Commune	Dropdown (liste DVF)	PARIS 10
Adresse	Texte libre (optionnel)	21 rue Proudhon, 93210 Saint-Denis
Surface (m²)	Numérique (±5 par bouton)	65
Nombre de pièces	Numérique (±1 par bouton)	3
Type de bien	Dropdown	Appartement / Maison / Studio

Estimation Immobilière — Paris

Prototype v0.2
10 March 2024

Accueil
Estimateur

ESTIMATION PERSONNALISÉE

Décrivez votre bien *immobilier*

Renseignez les caractéristiques pour obtenir une estimation basée sur le marché local.

Localisation

Commune

Sélectionnez une commune

Adresse (optionnel)

Ex: 21 rue proudhon, 93210 Saint Denis

Caractéristiques

Surface (m²)

Pièces

Type de bien

Appartement

Lancer l'estimation

Votre estimation apparaîtra ici

Complétez le formulaire puis cliquez sur « Lancer l'estimation ».

Fonctionnalité 3 — Résultat d'estimation

Après soumission, un panneau affiche le résultat structuré avec les éléments suivants :

- Prix total estimé (en €) affiché en grand.
- Prix au m² calculé à partir de la médiane des transactions similaires.
- Barre de fourchette interactive (Q1 – Q3) avec positionnement de l'estimation.
- Score de confiance : proportionnel au nombre de transactions trouvées (max à 50).
- Modèle utilisé : dvf (statistique) / ml-simple (RandomForest) / mock (fallback).

Information affichée	Source de calcul
Prix estimé total	médiane(prix_au_m2) × surface
Prix au m ²	médiane(prix_au_m2) des transactions similaires
Borne basse	Q1(prix_au_m2) × surface
Borne haute	Q3(prix_au_m2) × surface
Score de confiance	min(100 % ; n_transactions / 50 × 100)

Estimation Immobilière — Paris

Prototype v0.210 March 2024

Accueil

Estimateur

ESTIMATION PERSONNALISÉE

Décrivez votre bien *immobilier*

Renseignez les caractéristiques pour obtenir une estimation basée sur le marché local.

Localisation

Commune

ABLON-SUR-SEINE

Adresse (optionnel)

Ex: 21 rue proudhon, 93210 Saint Denis

Caractéristiques

Surface (m²)

65

Pièces

3

Type de bien

Appartement

Lancer l'estimation

ESTIMATION — ABLON-SUR-SEINE

€ 169 500,175

App. - 65 m² - 3 pièces

€ 2 608

3

65 m²

App.

€ 2 373

Fourchette

€ 2 938

Min

€ 169 500,175

Max

Modèle duf

Confiance: 100

Fonctionnalité 4 — API REST

Accès direct aux endpoints pour les développeurs ou les tests automatisés :

Endpoint	Méthode	Rôle
/api/health	GET	Statut backend, DVF chargé, modèle ML
/api/metadata/communes	GET	Liste des communes disponibles dans le dataset
/api/predictions/estimate	POST	Estimation de prix (payload JSON)

Exemple de requête / réponse API

```
// POST /api/predictions/estimate
{
  "area_m2": 65,
  "rooms": 3,
  "property_type": "apartment",
  "commune": "PARIS 10"
}

// Réponse
{
  "predicted_price": 458250.00,
  "price_per_m2": 7050.00,
  "confidence_interval": {
    "lower": 389012.00,
    "upper": 526987.00,
    "confidence": 85
  },
  "model": "dvf"
}
```

RealEstateAI Backend

0.1.0

QAS 1.1

api.openapi.json

default

GET

/api/health

Health

GET

/api/metadata/communes

Communes

POST

/api/predictions/estimate

Estimate

Schemas

EstimationRequest

>

Expand all

object

HTTPValidationError

>

Expand all

object

ValidationError

>

Expand all

object

Avancement global du prototype

Module	Avancement
Architecture	80 %
Backend API	75 %
Frontend	70 %
Pipeline Data	50 %
Modèle ML réel	20 %
Production ready	30 %
**Global	**≈ 60 %

Limites identifiées

Limite	Impact	Priorité
Pas de filtre outliers (IQR)	Estimation biaisée sur petits échantillons	Haute
ML moins précis que la baseline	Modèle non exploité en production	Haute
Granularité commune uniquement	Imprécis pour Paris intra-muros	Haute
Pas de base de données (CSV)	Pas de persistance, scalabilité limitée	Moyenne
2 lignes prix_au_m2 ≤ 0 résiduelles	Bruit marginal	Basse
Pas de déploiement cloud	Usage local uniquement	Moyenne

Pistes d'amélioration

1. Filtrage outliers : appliquer un filtre IQR ($Q1 - 1.5 \times IQR$; $Q3 + 1.5 \times IQR$) sur `prix_au_m2`.
2. Enrichissement des features : année de transaction, département, données INSEE (revenus, chômage).
3. Modèle plus performant : XGBoost / LightGBM avec validation croisée — objectif $MAPE < 30 \%$.
4. Granularité géographique : passer au niveau code postal (arrondissement Paris) voire IRIS.
5. Base de données : intégrer PostgreSQL (schéma déjà présent dans `db/init.sql`).
6. Carte interactive : visualisation des transactions similaires sur carte IGN / Leaflet.
7. Déploiement cloud : CI/CD GitHub Actions → VPS ou cloud (Render, Railway, OVH).
8. Tests automatisés : couverture unitaire complète des utils et endpoints.